

Explicación ampliada para PPT – Machine Learning and Deep Learning

1. Problemática (pp. 685–686, 690–693)

En la PPT (breve):

- Reglas fijas → insuficientes en entornos complejos.
- ML/DL permiten aprender de datos.
- Retos: sesgos, concept drift, explicabilidad, costos altos.

Explicación para exponer:

Antes de ML/DL se usaban sistemas expertos basados en reglas hechas por humanos. El problema es que los humanos no podemos formalizar todo el conocimiento. Ejemplo: definir todas las reglas que diferencian un auto deportivo de uno normal. ML/DL permiten que los modelos aprendan de ejemplos y datos complejos. Sin embargo, aparecen problemas: sesgos heredados en los datos, concept drift (los modelos dejan de ser válidos si cambian las condiciones), falta de explicabilidad (cajas negras) y costos computacionales elevados.

2. Contexto (pp. 685–689)

En la PPT (breve):

- Sector: mercados electrónicos y negocios digitales.
- Datos: series temporales, imágenes, texto.
- Aplicaciones: predicción de mercados, segmentación, fraude.

Explicación para exponer:

El artículo se sitúa en el área de mercados electrónicos y negocios digitales. Se usan datos como: series temporales (precios de acciones, procesos), imágenes (productos, conducción autónoma) y texto (reseñas de clientes, redes sociales, correos). Con estos datos se aplican tareas como predicción de mercados financieros, segmentación de clientes, análisis de sentimientos y detección de fraudes.

3. Métodos (pp. 686–690)

En la PPT (breve):

- Tipos de aprendizaje: supervisado, no supervisado, refuerzo.
- ML clásico: regresiones, árboles, SVM.
- DL: CNN, RNN, Embeddings, Autoencoders, GANs.

Explicación para exponer:

Los métodos se dividen en ML clásico y DL. Tipos de aprendizaje: supervisado (datos con etiquetas), no supervisado (patrones ocultos sin etiquetas) y por refuerzo (aprende con prueba y error). Algoritmos clásicos incluyen regresiones, árboles y SVM (Support Vector Machines). En DL se destacan las CNN (visión por computadora), RNN (series y lenguaje, con variantes como LSTM y Attention), Embeddings (representaciones semánticas en NLP), Autoencoders (compresión y detección de anomalías) y GANs (generación de datos sintéticos como deepfakes).

4. Contribuciones (pp. 686–693)

En la PPT (breve):

- Distinción conceptual: AI, ML, ANN, DL.
- Marco metodológico: datos → características → modelo → evaluación.
- Desafíos: arquitecturas, sesgos, explicabilidad, transferencia.

Explicación para exponer:

El artículo aclara la diferencia entre AI (Artificial Intelligence), ML (Machine Learning), ANN (Artificial Neural Networks) y DL (Deep Learning). Plantea un marco metodológico: entrada de datos, extracción de características, construcción de modelos y evaluación. Identifica 4 grandes desafíos: 1) equilibrio entre arquitecturas, hiperparámetros y datos; 2) manejo de sesgos y concept drift; 3) necesidad de explicabilidad (XAI, Explainable AI); 4) uso de transfer learning y AlaaS (Artificial Intelligence as a Service).

5. Conclusiones (pp. 692–693)

En la PPT (breve):

- ML/DL son pilares de los sistemas inteligentes.
- AlaaS democratiza modelos en la nube.
- Retos: explicabilidad, sesgos, balance precisión/costo.
- Impacto: integración masiva en negocios.

Explicación para exponer:

Los autores concluyen que ML y DL son la base de los sistemas inteligentes modernos. El futuro está en AlaaS, que permite acceder a modelos preentrenados en la nube sin necesidad de entrenarlos desde cero. Pero la adopción requiere modelos explicables, transparentes y resistentes a sesgos. El impacto es la integración masiva de IA en negocios, salud y finanzas, pero con retos éticos, técnicos y sociales (ej. deepfakes o decisiones injustas).